

Qualidade de Vinhos

Regressão para dados ordinais e binários

João Nogueira Kenzo Bontempo Gabriel Bertolucci

Tópicos em Estatística EST171
Prof. Cristiano de Carvalho Santos

Dados

```
raw <- rio::import(here("data", "winemagv2.csv"))
wine <- raw |>
  filter(!is.na(price), !is.na(country),
         !country %in% c("", "US-France")) |>
  mutate(
    points_ord = cut(points, c(80, 85, 87, 89, 91, 100),
                     include.lowest = TRUE, labels = 1:5,
                     ordered_result = TRUE),
    points_bin = as.integer(points >= 90),
    log_price = log(price),
    terroir = case_when(country %in% velho ~ "Velho Mundo",
                        country %in% novo ~ "Novo Mundo",
                        TRUE ~ "Outros"),
    # 5 uvas mais frequentes; demais em "Outras"
    variety_top = if_else(variety %in% top_var, variety, "Outras")
  )
```


Wine Enthusiast Reviews

Variável	Tipo	No modelo
points	Ordinal (80–100)	Resposta: 5 classes
price	Contínua (US\$)	log(price)
country	Nominal (42 países)	Região (3 grupos)
variety	Nominal (692 uvas)	Top 5 + Outras



	n	%
Avaliações	129.971	100,0%
Com preço registrado	120.916	93,0%
≥ 90 pontos	45.373	37,5%

Fonte: Kaggle, winemag-data-130k-v2.csv

Resposta ordinal: cinco classes




Covariáveis





Velho Mundo: França, Itália, Espanha, Portugal, Alemanha, Áustria **Novo Mundo:** EUA, Chile, Argentina, Austrália, África do Sul, Nova Zelândia

Vinhos por país




Preço × classe





Uva × classe



Tracejado: parcela abaixo de 90 pontos na amostra toda. Ordenado pela proporção de 90+.

Modelo ordinal

```
library(MASS)
m0 <- polr(points_ord ~ 1, data = wine, Hess = TRUE)
m1 <- update(m0, . ~ . + log_price)
m2 <- update(m1, . ~ . + terroir)
m3 <- update(m2, . ~ . + variety_top)      # modelo escolhido

anova(m0, m1, m2, m3)                      # TRV sequencial
AIC(m0, m1, m2, m3); BIC(m0, m1, m2, m3)

predict(m3, novos_dados, type = "probs") #  $P(Y = j \mid x)$ 
```

Modelo de chances proporcionais

Logitos acumulados

$$\text{logit } P(Y \leq j \mid \mathbf{x}) = \alpha_j - \mathbf{x}^\top \boldsymbol{\beta}, \quad j = 1, \dots, 4$$

Variável latente

$$Y^* = \mathbf{x}^\top \boldsymbol{\beta} + \varepsilon, \quad \varepsilon \sim \text{Logística}(0, 1)$$

$$Y = j \iff \alpha_{j-1} < Y^* \leq \alpha_j$$

Preditor

$$\mathbf{x}^\top \boldsymbol{\beta} = \beta_1 \log(\text{price}) + \beta_2 \mathbb{I}_{\text{Velho Mundo}} + \beta_3 \mathbb{I}_{\text{Outros}} + \sum_{k=1}^5 \gamma_k \mathbb{I}_{\text{uva}=k}$$

Seleção de variáveis

Pacote MASS: polr()

Modelo	Covariáveis	gl	Deviance	AIC	BIC	TRV (Δ gl)	p
m_0	—	4	387.245	387.253	387.292	—	—
m_1	log(price)	5	334.491	334.501	334.550	52.753,4 (1)	< 0,001
m_2	+ região	7	333.828	333.842	333.910	663,3 (2)	< 0,001
m_3	+ uva	12	333.325	333.349	333.465	503,4 (5)	< 0,001

Modelo	Redução de deviance vs. m_0	Ganho vs. anterior
m_1	13,6%	52.753
m_2	13,8%	663
m_3	13,9%	503


Modelo ajustado (m_3)

Pacote MASS: polr()

Parâmetro	Estimativa	EP	z	OR	IC 95% (OR)
Preço					
log(price)	2,184	0,011	204,8	8,88	[8,70; 9,07]
Região (ref.: Novo Mundo)					
Velho Mundo	0,223	0,012	19,3	1,25	[1,22; 1,28]
Outros países	0,165	0,037	4,4	1,18	[1,10; 1,27]
Uva (ref.: Outras)					
Bordeaux Blend	-0,245	0,026	-9,4	0,78	[0,74; 0,82]
Cabernet Sauvignon	-0,418	0,022	-19,3	0,66	[0,63; 0,69]
Chardonnay	-0,103	0,019	-5,4	0,90	[0,87; 0,94]
Pinot Noir	-0,111	0,019	-5,8	0,90	[0,86; 0,93]
Red Blend	-0,229	0,021	-11,0	0,80	[0,76; 0,83]
Pontos de corte					
α_1 (1 2)	5,134	0,033	156,0		
α_2 (2 3)	6,608	0,034	192,0		
α_3 (3 4)	7,860	0,036	215,8		
α_4 (4 5)	9,335	0,039	238,2		


Preço dobra: $2^{\hat{\beta}_1} = 4,54$ IC 95%: [4,48; 4,61]

Variável latente Y^* e limiares



Probabilidades preditas

Pacote MASS: `predict(m3, type = "probs")`



Uva fixada em "Outras"; um painel por região.

Chances proporcionais

```
brant::brant(m3)                                # teste de Brant

# um logito binario por corte: Y > j
colapsos <- map(1:4, \(j) glm(
  I(as.integer(points_ord) > j) ~ log_price + terroir + variety_top,
  family = binomial, data = wine))

# chances proporcionais parciais: regioao e uva livres por corte
fit_ppom <- VGAM::vglm(
  points_ord ~ log_price + terroir + variety_top,
  family = cumulative(parallel = FALSE ~ terroir + variety_top,
    reverse = TRUE), data = wine)
```

Teste de Brant

Pacote brant: brant()


$$H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4$$

Teste	χ^2	gl	p
Omnibus	1.602,7	24	< 0,001
log(price)	181,1	3	< 0,001
Velho Mundo	530,8	3	< 0,001
Outros países	128,8	3	< 0,001
Bordeaux Blend	39,0	3	< 0,001
Cabernet Sauvignon	24,7	3	< 0,001
Chardonnay	120,3	3	< 0,001
Pinot Noir	143,8	3	< 0,001
Red Blend	82,2	3	< 0,001

$$N = 120.916$$

Colapsamentos binários sucessivos

Pacote stats: `glm(family = binomial)`, um por corte



Tracejado: estimativa do modelo de chances proporcionais (m_3). Barras: IC 95%.

Chances proporcionais parciais

Pacote VGAM: `vglm()`, região e uva livres por corte

$$\text{logit } P(Y > j) = \alpha_j + \beta_1 \log(\text{price}) + \beta_j^\top \text{região} + \gamma_j^\top \text{uva}$$

Modelo	Parâm.	AIC	Vinhos com $\hat{P} < 0$	TRV vs. POM (gl)
Proporcional (POM)	12	333.349	0	—
Parcial: preço livre	15	indefinido	47	indefinido
Parcial: região e uva livres	33	331.977	0	1.414,0 (21), $p < 0,001$

No parcial, $\hat{\beta}_1 = 2,205$ (comum aos cortes).

Termo	$Y > 1$	$Y > 2$	$Y > 3$	$Y > 4$
α_j	-5,32	-6,68	-7,84	-9,36
Velho Mundo	0,56	0,28	0,03	0,03
Outros países	0,41	0,40	-0,03	-0,50
Bordeaux Blend	-0,43	-0,21	-0,18	-0,34
Cabernet Sauvignon	-0,37	-0,49	-0,44	-0,41
Chardonnay	-0,20	-0,19	-0,04	0,09
Pinot Noir	-0,28	-0,31	-0,19	0,09
Red Blend	-0,07	-0,16	-0,30	-0,40

Modelo binário

```
fit_bin <- glm(points_bin ~ log_price + terroir + variety_top,  
               family = binomial, data = wine)  
  
library(pROC)  
roc_bin <- roc(wine$points_bin, fitted(fit_bin))  
p_ord  <- rowSums(predict(m3, type = "probs")[, 4:5]) # P(Y >= 4)  
roc_ord <- roc(wine$points_bin, p_ord)  
  
auc(roc_bin); auc(roc_ord)  
coords(roc_bin, "best", # corte de Youden  
       ret = c("threshold", "sensitivity", "specificity"))
```


Dicotomização: 90+ pontos

Pacote stats: `glm(family = binomial)`

$$Y_{\text{bin}} = \mathbb{I}(\text{points} \geq 90) = \mathbb{I}(Y \in \{4, 5\}) \quad \text{logit } P(Y_{\text{bin}} = 1) = \beta_0 + \mathbf{x}^\top \boldsymbol{\beta}$$

	Ordinal $\hat{\beta}$ (EP)	Parcial $\hat{\beta}_3$	Binário $\hat{\beta}$ (EP)	OR ord.	OR bin.	$EP_{\text{bin}}^2 / EP_{\text{ord}}^2$
log(price)	2,18 (0,011)	2,20	2,24 (0,015)	8,88	9,35	1,88
Velho Mundo	0,22 (0,012)	0,03	0,08 (0,016)	1,25	1,08	1,79
Outros países	0,17 (0,037)	-0,03	-0,02 (0,052)	1,18	0,98	1,95
Bordeaux Blend	-0,25 (0,026)	-0,18	-0,20 (0,035)	0,78	0,82	1,76
Cabernet Sauvignon	-0,42 (0,022)	-0,44	-0,48 (0,029)	0,66	0,62	1,80
Chardonnay	-0,10 (0,019)	-0,04	-0,01 (0,025)	0,90	0,99	1,71
Pinot Noir	-0,11 (0,019)	-0,19	-0,15 (0,024)	0,90	0,86	1,55
Red Blend	-0,23 (0,021)	-0,30	-0,34 (0,028)	0,80	0,71	1,85

Discriminação: 90+ pontos



Youden: corte = 0,336 sensibilidade = 76,3% especificidade = 70,8%


Diagnóstico

```
# ordinal: residuos substitutos do pacote sure (amostra de 5.000)
sure::autoplot.polr(m3_amostra, what = "qq")

# binario: mesma construcao (Liu & Zhang) com J = 2
eta <- predict(bin_amostra, type = "link")
u    <- ifelse(y == 1, runif(n, plogis(-eta), 1),      # Y* > 0
              runif(n, 0, plogis(-eta)))             # Y* <= 0
r    <- qlogis(u)                                     # residuo ~ Logistica(0, 1)
```

Resíduos substitutos: ordinal


Pacote sure: `autoplot.polr()`



Amostra aleatória simples, $n = 5.000$.

Resíduos substitutos: binário

Construção de Liu & Zhang (2018) com $J = 2$: $R = S - \mathbf{x}^\top \hat{\beta}$, S logística truncada em $Y^* > 0$ ou $Y^* \leq 0$



Mesma amostra aleatória simples, $n = 5.000$.

Conclusão

```
# Cabernet Sauvignon de R$ 60 (cambio de R$ 5,16 por US$, fechamento de 30/09/2015)
nd <- tibble(log_price = log(60 / 5.16),
             terroir    = c("Novo Mundo", "Velho Mundo"),
             variety_top = "Cabernet Sauvignon")
p <- rowSums(predict(m3, nd, type = "probs")[, 4:5]) # P(90+)

chance <- p / (1 - p)
or <- chance[2] / chance[1] # = exp(beta_Velho Mundo)
```

Razão de chances × risco relativo

Relação

$$OR = \frac{\pi_1/(1 - \pi_1)}{\pi_0/(1 - \pi_0)} = RR \times \frac{1 - \pi_0}{1 - \pi_1}$$

Novo Mundo, outras uvas	$\hat{P}(90+)$	Chance $\hat{\pi}/(1 - \hat{\pi})$
US\$ 20	21,2%	0,269
US\$ 40	55,8%	1,265

OR	RR	$(1 - \pi_0)/(1 - \pi_1)$	Prevalência de 90+
4,71	2,64	1,79	37,5%

Exemplo: Cabernet Sauvignon de R\$ 60

Modelo ordinal m_3 : $\hat{P}(90+) = \hat{P}(Y \geq 4) = 1 - \text{logit}^{-1}(\hat{\alpha}_3 - \mathbf{x}^\top \hat{\beta})$

Vinho	US\$	$\hat{P}(90+)$	Chance	OR vs. 1ª linha
Cabernet, Novo Mundo, R\$ 60	11,6	5,1%	0,054	1,00
Cabernet, Novo Mundo, R\$ 120	23,3	19,7%	0,245	4,54
Cabernet, Velho Mundo, R\$ 60	11,6	6,3%	0,067	1,25
Cabernet, Outros países, R\$ 60	11,6	6,0%	0,064	1,18
Outra uva, Novo Mundo, R\$ 60	11,6	7,6%	0,082	1,52

OR no modelo de chances proporcionais

$$\text{OR} = \frac{\hat{P}_1/(1 - \hat{P}_1)}{\hat{P}_0/(1 - \hat{P}_0)} = \exp\{(\mathbf{x}_1 - \mathbf{x}_0)^\top \hat{\beta}\} \quad (\text{igual em todos os cortes})$$

Câmbio: R\$ 5,16 por US\$. Brasil tem 47 vinhos na base e, na nossa classificação, está em "Outros países".

Frases equivocadas

- ✗ *“Um vinho de US\$ 40 tem 4,7 vezes mais probabilidade de ter 90+ pontos do que um de US\$ 20.”*
- ✗ *“Como $OR = 1,08$, vinhos do Velho Mundo têm 8% mais chance de serem premiados, então 8% a mais deles têm 90+ pontos.”*
- ✗ *“Em regressão logística, $e^{\hat{\beta}}$ é o risco relativo.”*
- ✗ *“Dobrar o preço multiplica a chance de subir de classe por 4,5, então o vinho fica 4,5 vezes melhor.”*

Abordagem bayesiana

Priori regularizadora

$$\beta_k \sim \mathcal{N}(0, \sigma^2)$$

uvas e países raros: *shrinkage*

Modelo hierárquico

$$\text{logit } P(Y_i \leq j) = \alpha_j - \mathbf{x}_i^\top \beta - u_{\text{avaliador}[i]}, \quad u \sim \mathcal{N}(0, \sigma_u^2)$$

19 avaliadores (taster_name)

Posteriori de quantidades derivadas (MCMC)

$$p(\text{RR} \mid \text{dados}), \quad p(P(Y \geq 4 \mid \mathbf{x}) \mid \text{dados})$$

Referências

- Agresti, A. (2010). *Analysis of Ordinal Categorical Data*. 2ª ed. Wiley.
- Brant, R. (1990). Assessing proportionality in the proportional odds model for ordinal logistic regression. *Biometrics*, 46(4), 1171–1178.
- Peterson, B.; Harrell, F. E. (1990). Partial proportional odds models for ordinal response variables. *Applied Statistics*, 39(2), 205–217.
- Liu, D.; Zhang, H. (2018). Residuals and diagnostics for ordinal regression models: a surrogate approach. *JASA*, 113(522), 845–854.
- Thoutt, Z. (2017). *Wine Reviews*. Kaggle.
<https://www.kaggle.com/datasets/zynicide/wine-reviews>