

Qualidade de Vinhos

Regressão para dados ordinais e binários

João Nogueira Kenzo Bontempo Gabriel Bertolucci

Tópicos em Estatística EST171
Prof. Cristiano de Carvalho Santos


Wine Enthusiast Reviews

Variável	Tipo	No modelo
points	Ordinal (80–100)	Resposta: 5 classes
price	Contínua (US\$)	log(price)
country	Nominal (42 países)	Região (3 grupos)
variety	Nominal (692 uvas)	Top 5 + Outras



	n	%
Avaliações	129.971	100,0%
Com preço registrado	120.916	93,0%
≥ 90 pontos	45.373	37,5%

Fonte: Kaggle, winemag-data-130k-v2.csv

Resposta ordinal: quintis empíricos





Covariáveis



Velho Mundo: França, Itália, Espanha, Portugal, Alemanha, Áustria **Novo Mundo:** EUA, Chile, Argentina, Austrália, África do Sul, Nova Zelândia

Preço × classe





Modelo de chances proporcionais

Logitos acumulados

$$\text{logit } P(Y \leq j \mid \mathbf{x}) = \alpha_j - \mathbf{x}^\top \boldsymbol{\beta}, \quad j = 1, \dots, 4$$

Variável latente

$$Y^* = \mathbf{x}^\top \boldsymbol{\beta} + \varepsilon, \quad \varepsilon \sim \text{Logística}(0, 1)$$

$$Y = j \iff \alpha_{j-1} < Y^* \leq \alpha_j$$


Preditor

$$\mathbf{x}^\top \boldsymbol{\beta} = \beta_1 \log(\text{price}) + \beta_2 \mathbb{I}_{\text{Velho Mundo}} + \beta_3 \mathbb{I}_{\text{Outros}}$$

Mecânica da variável latente: Y^* e limiares

Discretização por pontos de corte fixos

$$Y^* = \mathbf{x}^\top \boldsymbol{\beta} + \varepsilon, \quad \varepsilon \sim \text{Logística}(0, 1), \quad Y = j \iff \alpha_{j-1} < Y^* \leq \alpha_j$$



Seleção de variáveis

Modelo	Covariáveis	gl	Deviance	AIC	BIC	TRV (Δ gl)	p
m_0	—	4	375.301	375.309	375.347	—	—
m_1	log(price)	5	323.052	323.062	323.111	52.248,6 (1)	< 0,001
m_2	+ região	7	322.480	322.494	322.562	572,4 (2)	< 0,001
m_3	+ uva	12	322.002	322.026	322.142	477,9 (5)	< 0,001


Modelo	Redução de deviance vs. m_0	Ganho vs. anterior
m_1	13,9%	52.249
m_2	14,1%	572
m_3	14,2%	478

Modelo ajustado (m_2)

Parâmetro	Estimativa	EP	z	OR	IC 95% (OR)
Efeitos					
log(price)	2,151	0,010	204,9	8,59	[8,42; 8,77]
Velho Mundo	0,261	0,011	23,8	1,30	[1,27; 1,33]
Outros	0,194	0,038	5,1	1,21	[1,13; 1,31]
Pontos de corte					
α_1 (1 2)	5,835	0,034	172,3		
α_2 (2 3)	7,321	0,036	203,8		
α_3 (3 4)	7,848	0,037	213,4		
α_4 (4 5)	9,322	0,040	235,6		

	OR	IC 95%
Preço dobra ($2^{\hat{\beta}_1}$)	4,44	[4,38; 4,51]

Probabilidades preditas




Teste de Brant

$$H_0 : \beta_1 = \beta_2 = \beta_3 = \beta_4$$

Teste	χ^2	gl	p
Omnibus	932,1	9	< 0,001
log(price)	168,1	3	< 0,001
Velho Mundo	582,7	3	< 0,001
Outros	172,9	3	< 0,001

$$N = 120.916$$

Colapsamentos binários sucessivos



Tracejado: estimativa do modelo de chances proporcionais (m_2).

Chances proporcionais parciais

$$\text{logit } P(Y > j) = \alpha_j + \beta_1 \log(\text{price}) + \beta_2 \mathbb{I}_{\text{VM}} + \beta_3 \mathbb{I}_{\text{Outros}}$$

Modelo	Parâm.	AIC	$\min \hat{P}(Y = j)$
Proporcional (POM)	7	322.494	0,0000
Parcial: preço livre	10	NaN	-0,0005
Parcial: região livre	13	321.638	0,0000


Corte	α_j	Velho Mundo	Outros	$\log(\text{price})$
$Y > 1$	-5,974 (0,035)	0,504 (0,015)	0,450 (0,050)	2,163 (0,011)
$Y > 2$	-7,356 (0,036)	0,245 (0,013)	0,369 (0,046)	
$Y > 3$	-7,813 (0,037)	0,092 (0,014)	-0,017 (0,050)	
$Y > 4$	-9,262 (0,040)	0,041 (0,018)	-0,552 (0,081)	

	TRV	gl	p
TRV: parcial vs. POM	867,4	6	< 0,001

Diagnóstico: resíduos substitutos (Liu & Zhang, 2018)

Definição: resíduo substituto contínuo (sure)

$$R_S = S - \mathbf{x}^\top \hat{\beta}, \quad S \mid (Y = j) \sim \text{Logística Truncada em } (\hat{\alpha}_{j-1}, \hat{\alpha}_j)$$



Liu & Zhang (2018, JASA); Greenwell et al. (2018, *The R Journal*). Amostra aleatória simples, $n = 5.000$.

Dicotomização: 90+ pontos


$$Y_{\text{bin}} = \mathbb{I}(\text{points} \geq 90) = \mathbb{I}(Y \in \{4, 5\})$$

$$\text{logit } P(Y_{\text{bin}} = 1) = \beta_0 + \mathbf{x}^\top \boldsymbol{\beta}$$

	Ordinal $\hat{\beta}$	(EP)	Parcial $\hat{\beta}_3$	Binário $\hat{\beta}$	(EP)	$EP_{\text{bin}}^2/EP_{\text{ord}}^2$
log(price)	2,151	0,0105	2,163	2,178	0,0140	1,77
Velho Mundo	0,261	0,0110	0,092	0,136	0,0144	1,73
Outros	0,194	0,0378	-0,017	-0,010	0,0519	1,89

	OR ordinal	OR binário	IC 95% (binário)
log(price)	8,59	8,83	[8,59; 9,07]
Velho Mundo	1,30	1,15	[1,11; 1,18]
Outros	1,21	0,99	[0,89; 1,10]

Discriminação: 90+ pontos



Youden: corte = 0,345 sensibilidade = 75,0% especificidade = 71,9%

Razão de chances × risco relativo

Relação

$$OR = \frac{\pi_1/(1 - \pi_1)}{\pi_0/(1 - \pi_0)} = RR \times \frac{1 - \pi_0}{1 - \pi_1}$$

Vinho do Novo Mundo	$\hat{P}(90+)$	Chance $\hat{\pi}/(1 - \hat{\pi})$
US\$ 20	19,8%	0,246
US\$ 40	52,7%	1,115

OR	RR	$(1 - \pi_0)/(1 - \pi_1)$	Prevalência de 90+
4,53	2,67	1,70	37,5%

Frases equivocadas

- ✗ *“Um vinho de US\$ 40 tem 4,5 vezes mais probabilidade de ter 90+ pontos do que um de US\$ 20.”*
- ✗ *“Como $OR = 1,15$, vinhos do Velho Mundo têm 15% mais chance de serem premiados, então 15% a mais deles têm 90+ pontos.”*
- ✗ *“Em regressão logística, $e^{\hat{\beta}}$ é o risco relativo.”*
- ✗ *“Dobrar o preço multiplica a chance de subir de classe por 4,4, então o vinho fica 4,4 vezes melhor.”*

Abordagem bayesiana

Priori regularizadora

$$\beta_k \sim \mathcal{N}(0, \sigma^2)$$

uvas e países raros: *shrinkage*

Modelo hierárquico

$$\text{logit } P(Y_i \leq j) = \alpha_j - \mathbf{x}_i^\top \beta - u_{\text{avaliador}[i]}, \quad u \sim \mathcal{N}(0, \sigma_u^2)$$

19 avaliadores (taster_name)

Posteriori de quantidades derivadas (MCMC)

$$p(\text{RR} \mid \text{dados}), \quad p(P(Y \geq 4 \mid \mathbf{x}) \mid \text{dados})$$

Referências

- Agresti, A. (2010). *Analysis of Ordinal Categorical Data*. 2ª ed. Wiley.
- Brant, R. (1990). Assessing proportionality in the proportional odds model for ordinal logistic regression. *Biometrics*, 46(4), 1171–1178.
- Peterson, B.; Harrell, F. E. (1990). Partial proportional odds models for ordinal response variables. *Applied Statistics*, 39(2), 205–217.
- Liu, D.; Zhang, H. (2018). Residuals and diagnostics for ordinal regression models: a surrogate approach. *JASA*, 113(522), 845–854.
- Thoutt, Z. (2017). *Wine Reviews*. Kaggle.
<https://www.kaggle.com/datasets/zynicide/wine-reviews>